

[LAB 07] 6. 일원분산분석

#연습문제 -(2)

```
1 from hossam import load_data
2 from helpers import *
3 from pandas import pivot_table
```

아이티월 이광호 강사가 제작한 라이브러리를 사용중입니다.
자세한 사용 방법은 <https://py.hossam.kr> 을 참고하세요.
Email: leekh4232@gmail.com
Youtube: <https://www.youtube.com/@hossam-codingclub>
Blog: <https://blog.hossam.kr/>
Version: 0.5.19

문제 1 - 독서 점수의 평균에 차이가 있다면 구체적으로 어떤 차이가 있는지 검정하라

```
1 df1 = load_data('reading')
2 df1.head()
```

유아들을 대상으로 세 가지 읽는 방법을 비교, 실험하여 얻은 독서평가 점수 데이터 (출처: 방송통신대학교 통계학개론)


	독서방법	점수
0	B	7.700
1	B	1.500
2	B	4.300
3	B	5.400
4	B	4.300

```
1 my_stats.posthoc_oneway(df1, y='점수', between='독서방법')
```

p-value annotation legend:
ns: 5.00e-02 < p <= 1.00e+00
*: 1.00e-02 < p <= 5.00e-02
**: 1.00e-03 < p <= 1.00e-02
***: 1.00e-04 < p <= 1.00e-03
****: p <= 1.00e-04

B vs. D: Custom statistical test, P_val:3.400e-01
D vs. G: Custom statistical test, P_val:4.031e-04
B vs. G: Custom statistical test, P_val:8.764e-05





	test	A	B	mean_A	mean_B	diff	se	T	df
0	Games-Howell	B	D	5.732	6.693	-0.961	0.677	-1.421	40.563
1	Games-Howell	B	G	5.732	12.531	-6.799	1.457	-4.666	42.964
2	Games-Howell	D	G	6.693	12.531	-5.838	1.363	-4.284	34.361

- 데이터가 등분산성을 만족하지 않아 Games-Howell을 수행하였다.
- 사후 분석 결과, B와 G 집단, D와 G집단의 평균 차이가 통계적으로 유의하였다($p < 0.05$)
- B와 G 집단의 평균은 각각 5.732, 12.531로 평균 차이는 -6.799였으며 효과크기는 -1.137로 큰 수준이었다. 즉 G집단의 평균이 B집단보다 유의하게 높았다.
- D와 G 집단의 평균은 각각 6.693, 12.531로 평균 차이는 -5.838이었으며, 효과 크기는 -1.044로 큰 수준이었다. 즉 G집단의 평균이 D집단보다 유의하게 높았다.
- 반면 B와 D($p > 0.05$)의 평균차이는 통계적으로 유의하지 않았다.

문제 2- 서울시 상권 종류에 따라 평균 매출액에 차이가 있다면 구체적으로 어떤 차이가 있는지 검정하라

```
1 df2 = load_data('commercial')
2 df2.head()
```

서울시의 2023년 상권에 따른 분기별 매출액과 매출건수에 대한 자료 (출처: 서울 열린데이터 광장)

	quarter	code	type	name	sales_amount	number_of_sales
0	1	3001491	관광 특구	이태원 관광특구	72523644100	2496865
1	1	3001492	관광 특구	명동 남대문 북창동 다동 무교동 관광특구	283332346393	10246122
2	1	3001493	관광 특구	동대문패션타운 관광특구	81696730221	2880324
3	1	3001494	관광 특구	종로·청계관광특구	212062656625	4960006

4	1	3001495	관광 특구	잠실 관광 특구	231338386876	5995166
---	---	---------	----------	-------------	--------------	---------

1 | my_stats.posthoc_oneway(df2, y='sales_amount', between='type')

p-value annotation legend:

ns: 5.00e-02 < p <= 1.00e+00

*: 1.00e-02 < p <= 5.00e-02

** : 1.00e-03 < p <= 1.00e-02

***: 1.00e-04 < p <= 1.00e-03

****: p <= 1.00e-04

골목상권 vs. 관광특구: Custom statistical test, P_val:6.410e-09


관광특구 vs. 발달상권: Custom statistical test, P_val:7.128e-07

발달상권 vs. 전통시장: Custom statistical test, P_val:3.927e-13

골목상권 vs. 발달상권: Custom statistical test, P_val:7.272e-14

관광특구 vs. 전통시장: Custom statistical test, P_val:1.140e-08

골목상권 vs. 전통시장: Custom statistical test, P_val:0.000e+00



	test	A	B	mean_A	mean_B	di
0	Games-Howell	골목상권	관광특구	3659508698.643	228143191041.625	-224483682342.98
1	Games-Howell	골목상권	발달상권	3659508698.643	57063096491.533	-53403587792.891
2	Games-Howell	골목상권	전통시장	3659508698.643	10584197874.740	-6924689176.098
3	Games-Howell	관광특구	발달상권	228143191041.625	57063096491.533	171080094550.092
4	Games-Howell	관광특구	전통시장	228143191041.625	10584197874.740	217558993166.885
	Games-Howell	발달상권	전통시장			

5	Games-Howell	골목상권	전통시장	57063096491.533	10584197874.740	46478898616.793
---	--------------	------	------	-----------------	-----------------	-----------------

- 데이터가 등분산성을 만족하지 않아 Games-Howell을 수행하였다.
- 사후 분석 결과, 모든 집단의 평균 차이가 통계적으로 유의하였다($p < 0.05$)
- 골목상권과 관광특구의 평균은 각각 3659508698.643, 228143191041.625로 평균 차이는 -224483682342.982였으며 효과크기는 -23.207로 매우 큰 수준이었다. 즉 관광특구의 평균이 골목상권보다 유의하게 높았다.
- 골목상권과 발달상권의 평균은 각각 3659508698.643, 57063096491.533로 평균 차이는 -53403587792.891였으며 효과크기는 -1.160로 큰 수준이었다. 즉 발달상권의 평균이 골목상권보다 유의하게 높았다.
- 골목상권과 전통시장의 평균은 각각 3659508698.643, 10584197874.740로 평균 차이는 -6924689176.098였으며 효과크기는 -0.679로 중간 수준이었다. 즉 전통시장의 평균이 골목상권보다 유의하게 높았다.
- 관광특구와 발달상권의 평균은 각각 228143191041.625, 57063096491.533로 평균 차이는 171080094550.092였으며 효과크기는 1.647로 큰 수준이었다. 즉 관광특구의 평균이 발달상권보다 유의하게 높았다.
- 관광특구와 전통시장의 평균은 각각 228143191041.625, 10584197874.740로 평균 차이는 217558993166.885였으며 효과크기는 8.537로 큰 수준이었다. 즉 관광특구의 평균이 전통시장보다 유의하게 높았다.
- 발달상권과 전통시장의 평균은 각각 57063096491.533, 10584197874.740로 평균 차이는 46478898616.793였으며 효과크기는 0.639로 중간 수준이었다. 즉 발달상권의 평균이 전통시장보다 유의하게 높았다.

문제 3 - 카페에서 음료 종류에 따라 매출 구분에 차이가 있는지 확인하라

1

df3 = load_data('cafe_sales')

2

df3.head()

 서울의 한 오피스 상권 카페에서 점심시간(11:30~13:30) 동안 판매된 음료 주문 데이터

	주문번호	주문시각	구분	메뉴명	사이즈	금액
0	1001	2026-03-31 11:32	커피	아메리카노	레귤러	4500
1	1002	2026-03-31 11:34	커피	카페라떼	레귤러	5000
2	1003	2026-03-31 11:35	커피	아메리카노	라지	5000
3	1004	2026-03-31 11:36	커피	콜드브루	레귤러	5300
4	1005	2026-03-31 11:38	에이드	자몽에이드	레귤러	5800

1

my_stats.anova_oneway(df3, y='금액', between='구분')

	test	Source	ddof1	ddof2	F	p_unc	np2	effect_siz
0	welch_anova	구분	2	10.566	32.978	0.000	0.489	Large

- 검정 선택 : test=welch_anova → 등분산성을 위반하여 Welch ANOVA 검정으로 진행하였다.
- 유의성 : $F(2, 10.566)=32.978, p=0.000<0.05$ → 귀무가설 기각, 세가지 음료 종류 중 적어도 한종류의 매출 평균은 다르다.
- 효과 크기 : $\eta^2=0.489$ → Large, 음료 종류의 매출 차이 변동의 약 48.9%를 설명, 통계적 유의성을 넘어 실질적으로도 큰 효과를 보였다.
- 다음 단계 : ANOVA는 '어딘가 차이가 있다'까지만 말해주므로, 어느 음료 종류의 쌍이 매출 금액이 다른지는 사후검정 등으로 확인 필요하다.

```
1 | my_stats.posthoc_oneway(df3, y='금액', between='구분')
```

p-value annotation legend:

```


ns: 5.00e-02 < p <= 1.00e+00
*: 1.00e-02 < p <= 5.00e-02
**: 1.00e-03 < p <= 1.00e-02
***: 1.00e-04 < p <= 1.00e-03
****: p <= 1.00e-04

```

```

에이드 vs. 차: Custom statistical test, P_val:1.177e-04
차 vs. 커피: Custom statistical test, P_val:8.083e-01
에이드 vs. 커피: Custom statistical test, P_val:2.758e-05

```



	test	A	B	mean_A	mean_B	diff	se	T	
0	Games-Howell	에이드	차	5966.667	4900.000	1066.667	145.297	7.341	8.
1	Games-Howell	에이드	커피	5966.667	4979.310	987.356	130.506	7.566	1.
2	Games-Howell	차	커피	4900.000	4979.310	-79.310	126.177	-0.629	9.

- 데이터가 등분산성을 만족하지 않아 Games-Howell을 수행하였다.
- 사후 분석 결과, 에이드와 차, 에이드와 커피의 평균 차이가 통계적으로 유의하였다 ($p < 0.05$)
- 에이드와 차의 평균은 각각 5966.667, 4900로 평균 차이는 1066.667였으며 효과크기는 4.006로 큰 수준이었다. 즉 에이드의 매출평균이 차보다 유의하게 높았다.
- 에이드와 커피의 평균은 각각 5966.667, 4979.31로 평균 차이는 987.356이었으며,

효과 크기는 2.444로 큰 수준이었다. 즉 에이드의 매출평균이 커피보다 유의하게 높았다.

- 반면 차와 커피($p \geq 0.05$)의 매출 평균차이는 통계적으로 유의하지 않았다.

문제 4- 요일별로 평균 팁 금액에 차이가 있는지 알아봐라

```
1 df4 = load_data('tips')
2 df4.head()
```

 식당 고객의 결제 금액, 팁, 성별, 흡연 여부, 요일, 시간대, 일행 규모 등 기본 정보를 담은 데이터 분석·시각화 실습용 샘플 데이터 (출처: <https://www.kaggle.com/datasets/sakshisatre/tips-dataset>)

field	description
total_bill	총 결제 금액
tip	팁 금액
sex	성별
smoker	흡연 여부
day	방문 요일
time	방문 시간대
size	일행 규모

	total_bill	tip	sex	smoker	day	time	size
0	16.990	1.010	Female	No	Sun	Dinner	2
1	10.340	1.660	Male	No	Sun	Dinner	3
2	21.010	3.500	Male	No	Sun	Dinner	3
3	23.680	3.310	Male	No	Sun	Dinner	2
4	24.590	3.610	Female	No	Sun	Dinner	4

```
1 df4['day'].unique()
```

<ArrowStringArray>
['Sun', 'Sat', 'Thur', 'Fri']
Length: 4, dtype: str

```
1 my_stats.anova_oneway(df4, y='total_bill', between='day')
```

	test	Source	ddof1	ddof2	F	p_unc	np2	effect_size
0	welch_anova	day	3	75.305	3.011	0.035	0.033	Small

- 검정 선택 : test=welch_anova → 등분산성을 위반하여 Welch ANOVA 검정으로 진행하였다.
- 유의성 : $F(3, 75.305)=3.011, p=0.035 < 0.05$ → 귀무가설을 기각하고 대립가설을 채택, 요일별로 주문금액에 차이가 있다.
- 효과 크기 : $np2=0.020$ → Small, 요일별로 평균 주문 금액의 차이가 약 3.3%를 설명, 통계적 유의성이 작다.(실질적으로 작은 효과)


• 다음 단계 : 요일별로 평균 주문금액에 차이가 있으므로 사후 검정 필요

```
1 | my_stats.posthoc_oneway(df4, y='total_bill', between='day')
```

p-value annotation legend:

ns: $5.00e-02 < p \leq 1.00e+00$
*: $1.00e-02 < p \leq 5.00e-02$
**: $1.00e-03 < p \leq 1.00e-02$
***: $1.00e-04 < p \leq 1.00e-03$
****: $p \leq 1.00e-04$

Fri vs. Sat: Custom statistical test, P_val:4.367e-01
Sat vs. Sun: Custom statistical test, P_val:9.064e-01
Sun vs. Thur: Custom statistical test, P_val:4.812e-02
Fri vs. Sun: Custom statistical test, P_val:2.210e-01
Sat vs. Thur: Custom statistical test, P_val:2.188e-01
Fri vs. Thur: Custom statistical test, P_val:9.946e-01



	test	A	B	mean_A	mean_B	diff	se	T	
0	Games-Howell	Fri	Sat	17.152	20.441	-3.290	2.159	-1.524	29.27
1	Games-Howell	Fri	Sun	17.152	21.410	-4.258	2.157	-1.974	29.06
2	Games-Howell	Fri	Thur	17.152	17.683	-0.531	2.152	-0.247	28.66
3	Games-Howell	Sat	Sun	20.441	21.410	-0.969	1.435	-0.675	160.3
4	Games-Howell	Sat	Thur	20.441	17.683	2.759	1.427	1.933	143.4
5	Games-Howell	Sun	Thur	21.410	17.683	3.727	1.425	2.616	134.8

- 데이터가 등분산성을 만족하지 않아 Games-Howell을 수행하였다.
- 사후 분석 결과, 일요일과 목요일의 주문금액평균 차이가 통계적으로 유의하였다($p < 0.05$)
- 일요일과 목요일의 평균은 각각 21.41, 17.683로 평균 차이는 3.727이었으며, 효과 크기는 0.440로 작은 수준이었다. 즉 일요일의 주문금액이 목요일보다 유의하게 높았다.

- 반면 금요일과 토요일, 금요일과 일요일, 금요일과 목요일, 토요일과 일요일, 토요일과 목요일($p \geq 0.05$)의 주문 금액 평균차이는 통계적으로 유의하지 않았다.