

[LAB 07] 12-1. 교차분석의 이해

연습문제

```
1 from hossam import load_data
2 from helpers import *
3
4 from pandas import DataFrame
```

```
1 origin = load_data('wage')
2 origin.head()
```

 경제 및 노동 시장에 관련된 정보를 담고 있는 데이터셋 (출처: ADsP 기출문제)

	field	description
--	-----	-----
0	year	년도
1	age	나이
2	maritl	결혼여부
3	race	근로자의 인종
4	education	교육수준
5	region	지역
6	jobclass	직군
7	health	건강상태
8	health_ins	건강보험 가입 여부
9	logwage	임금 (로그값)
10	wage	임금

	year	age	maritl	race	education	region	jobclass	health
0	2006	18	1. Never Married	1. White	1. < HS Grad	2. Middle Atlantic	1. Industrial	1. <=Good
1	2004	24	1. Never Married	1. White	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good
2	2003	45	2. Married	1. White	3. Some College	2. Middle Atlantic	1. Industrial	1. <=Good
3	2003	43	2. Married	3. Asian	4. College Grad	2. Middle Atlantic	2. Information	2. >=Very Good
4	2005	50	4. Divorced	1. White	2. HS Grad	2. Middle Atlantic	2. Information	1. <=Good


```
1 df = origin.copy()
2 for c in ['maritl', 'race', 'education', 'region', 'jobclass',
3 'health', 'health_ins']:
4     df[c] = df[c].str.replace(r'^\d+\.\s*', '', regex=True)
```

```
df.head()
```

	year	age	maritl	race	education	region	jobclass	health
0	2006	18	Never Married	White	< HS Grad	Middle Atlantic	Industrial	<=Good
1	2004	24	Never Married	White	College Grad	Middle Atlantic	Information	>=Very Good
2	2003	45	Married	White	Some College	Middle Atlantic	Industrial	<=Good
3	2003	43	Married	Asian	College Grad	Middle Atlantic	Information	>=Very Good
4	2005	50	Divorced	White	HS Grad	Middle Atlantic	Information	<=Good

문제 1. 절반씩 일하나요? Industrial 직군과 Information 직군에 정확히 절반씩 나뉘어 있다고 봐도 되는지? 유의수준 5%에서 '두 직군의 균등하게 분포한다'는 귀무가설에 대한 판정은?

```
1 # 적합도 검정
2 my_stats.chi2_goodness_of_fit(df, 'jobclass')
```




	chi2	dof	p-value	significant	effect(w)	strength	min_expect
Chi-square goodness-of-fit	2.581	1	0.108	False	0.029	Negligible	1500.000

- p-value = 0.108 > 0.05 이므로 귀무가설을 채택한다. 두 직군은 균등하게 분포한다고 볼 수 있다.

문제 2. 교육을 더 받은 사람일수록 Information 직군에서 일하는지 아니면 교육수준과 직군은 무관한지?

```
1 my_stats.chi2_independence(df, 'education', 'jobclass',
2 orient='h', palette='Set2',
                                xlabel='교육수준', height=400)
```




		test	chi2	dof	p-value	significant	effect size
row	col						
education	jobclass	Chi-square test of independence	282.643	4	0.000	True	0.307

- p-value = 0.000 < 0.05 이므로 교육수준과 직군은 무관하지 않고 통계적으로 유의한 관련이 있다고 볼 수 있다.
- 그래프를 보면 '< HS Grad'와 'HS Grad'는 Industrial 비율이 높고, 'College Grad'와 'Advanced Degree'는 Information 비율이 높다.
- 따라서 교육수준이 높을수록 Information 직군에서 일하는 경향이 있다고 해석할 수 있다. Cramer's V = 0.307로 관련성의 강도는 중간 수준이다.

문제 3. 건강보험 미가입자를 줄이는 캠페인을 하려는데 가장 우선 지원해야할 교육수준 집단은?

```
1 my_stats.chi2_independence(df, 'education', 'health_ins',
2 orient='h', palette='Set2',
                                xlabel='교육수준', height=400)
```




		test	chi2	dof	p-value	significant	eff
row	col						
education	health_ins	Chi-square test of independence	141.635	4	0.000	True	0.2

- 교육수준과 건강보험 가입 여부의 교차분석 결과, $p\text{-value} = 0.000 < 0.05$ 교육수준과 건강보험 가입 여부는 통계적으로 유의한 관련이 있다. 다만 Cramer's $V = 0.217$ 로 관련성의 강도는 약한 수준이다.
- 교육수준별 미가입(No) 비율을 보면 '< HS Grad'가 53.7%로 가장 높으므로, 건강보험 미가입자를 줄이기 위한 캠페인에서는 '< HS Grad' 집단을 가장 우선 지원해야 할 집단으로 선정하는 것이 적절하다.

문제 4. Industrial 직군과 Information 직군 두 집단의 건강보험 가입 분포가 같은 지 비교

```
1 my_stats.chi2_independence(df, 'jobclass', 'health_ins',
2 orient='h', palette='Set2',
  xlabel='직군', height=400)
```




		test	chi2	dof	p-value	significant	effect
row	col						
jobclass	health_ins	Chi-square test of independence	66.126	1	0.000	True	0.148

- 직군과 건강보험 가입 여부의 교차분석 결과, $p\text{-value} = 0.000 < 0.05$ 직군과 건강보험 가입 여부는 통계적으로 유의한 관련이 있다.
- 다만 Cramer's $V = 0.148$ 로 관련성의 강도는 약한 수준이다.
- 직군별 건강보험 가입(Yes) 비율을 보면 'Information'이 76.5%로 더 높은 것으로 나타났다.

문제 5. 임금과 가장 강하게 연결된 범주형 원지 비교


```
1 q75 = df['wage'].quantile(0.75)
2
3 df['임금'] = '일반임금'
4 df.loc[df['wage'] >= q75, '임금'] = '고임금'
```

```
1 my_stats.chi2_independence(df, 'education', '임금', orient='h',
2 palette='Set2',
                                xlabel='교육수준', height=400)
```



		test	chi2	dof	p-value	significant	effect(v)
row	col						
education	임금	Chi-square test of independence	567.564	4	0.000	True	0.435

```
1 my_stats.chi2_independence(df, 'jobclass', '임금', orient='h',
2 palette='Set2',
                                xlabel='직군', height=400)
```




		test	chi2	dof	p-value	significant	effect(v)
--	--	------	------	-----	---------	-------------	-----------

		test	chi2	dof	p-value	significant	effect(v)	strength
row	col							
jobclass	임금	Chi-square test of independence	63.346	1	0.000	True	0.145	Weak

```

1 my_stats.chi2_independence(df, 'health', '임금', orient='h',
2 palette='Set2',
                                xlabel='건강수준', height=400)

```



		test	chi2	dof	p-value	significant	effect(v)	strength
row	col							
health	임금	Chi-square test of independence	49.404	1	0.000	True	0.128	Weak

- 임금과 education, jobclass, health의 관련성을 각각 카이제곱 독립성 검정으로 확인하였다.
- 세 변수 모두 p-value = 0.000 < 0.05로 나타나 임금과 통계적으로 유의한 관련이 있었다.
- 그 중 Cramer's V(effect(v)) 값은 education이 0.435로 가장 컸고, 관련성의 강도는 중간 수준(Moderate)으로 나타났다. jobclass는 0.145, health는 0.128로 모두 약한 수준(Weak)이었다.
- 따라서 임금(상위 25%를 고임금으로 구분)과 가장 강하게 연결된 범주형 변수는 education이다.