

[LAB 08] 1. EDA 시작하기

#연습문제

```
1 from hossam import load_data
2 from helpers import *
```

 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
 자세한 사용 방법은 <https://py.hossam.kr> 을 참고하세요.
 Email: leekh4232@gmail.com
 Youtube: <https://www.youtube.com/@hossam-codingclub>
 Blog: <https://blog.hossam.kr/>
 Version: 0.5.19

```
1 origin = load_data('insurance_qtcheck')
2 print(origin.shape)
3 print(origin.head())
```

 보험 비용 데이터셋의 품질 검사 완료 버전 (출처: 자체 정제)
(1337, 7)

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.924
1	18	male	33.770	1	no	southeast	1725.552
2	28	male	33.000	3	no	southeast	4449.462
3	33	male	22.705	0	no	northwest	21984.471
4	32	male	28.880	0	no	northwest	3866.855

- 보험 비용 데이터 셋의 행과 열은 각각 1337, 7이며 컬럼은 age, sex, bmi, children, smoker, region, charges이고 목표변수는 보험 비용인 charges 이다.

```
1 desc = load_data('insurance_qtcheck_desc')
2 desc.T
```

 보험 비용 데이터셋의 연속형 변수에 대한 기술 통계량 (출처: 자체 작업)

	age	bmi	children	charges
count	1337.000	1337.000	1337.000	1337.000
mean	39.222	30.663	1.096	13279.121
std	14.044	6.100	1.206	12110.360
min	18.000	15.960	0.000	1121.874
25%	27.000	26.290	0.000	4746.344
50%	39.000	30.400	1.000	9386.161
75%	51.000	34.700	2.000	16657.717
max	64.000	53.130	5.000	63770.428
rel_diff	0.006	0.009	0.096	0.415

rdiff_flag	similar	similar	similar	diff
iqr	24.000	8.410	2.000	11911.373
upper_bound	87.000	47.315	5.000	34524.778
lower_bound	-9.000	13.675	-3.000	-13120.716
upper_outliers	0	9	0	139
upper_outliers_ratio	0.000	0.007	0.000	0.104
lower_outliers	0	0	0	0
lower_outliers_ratio	0.000	0.000	0.000	0.000
outliers	0	9	0	139
outliers_ratio	0.000	0.007	0.000	0.104
skew	0.055	0.284	0.937	1.515
skew_interpret	symmetric	symmetric	right tail	right tail
kurt	-1.244	-0.053	0.201	1.604
kurt_interpret	platykurtic	platykurtic	leptokurtic	leptokurtic
log_need	none	none	log1p	log1p

- children, charges가 로그 변환 후보이다. 둘다 오른쪽 꼬리 분포를 보인다.

```

1 | cat_desc = load_data('insurance_qtcheck_category_desc')
2 | cat_desc

```

 보험 비용 데이터셋의 범주형 변수에 대한 기술 통계량 (출처: 자체 작업)

	Unnamed: 0	sex	smoker	region
0	count	1337	1337	1337
1	unique	2	2	4
2	top	male	no	southeast
3	freq	675	1063	364

- sex, smoker, region이 명목형 변수이며 이중 smoker의 freq이 1063으로 한쪽으로 쏠렸다고 볼 수 있다. 심한 불균형이나 흡연 여부는 보험 비용에 영향을 줄 수 있는 변수이기 때문에 버리지 말고 검정으로 확인하는 것이 필요할 것으로 보인다.

```

1 | origin.info()

```

```

<class 'pandas.DataFrame'>
RangeIndex: 1337 entries, 0 to 1336
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         1337 non-null   int64
1   sex         1337 non-null   category
2   bmi         1337 non-null   float64
3   children    1337 non-null   int64

```

```
3  children    1337 non-null    int64
4  smoker      1337 non-null    category
5  region      1337 non-null    category
6  charges     1337 non-null    float64
dtypes: category(3), float64(2), int64(2)
memory usage: 45.9 KB
```

- 명목형 변수는 이미 범주형 타입으로 잘 지정되어 있으므로 별도의 타입 변환은 필요 없다.

```
1  목표변수 = 'charges'
2
3  연속형_설명변수 = ['age', 'bmi', 'children']
4  범주형_설명변수 = ['sex', 'smoker', 'region']
5
6  print(목표변수)
7  print(연속형_설명변수)
8  print(범주형_설명변수)
```

```
charges
['age', 'bmi', 'children']
['sex', 'smoker', 'region']
```