

[LAB 08] 2. 데이터 시각화

#연습문제

```
1 %%capture cap
2 %run "./08. PBT - EDA | 1-EDA 시작하기(연습문제).ipynb"
```

```
1 print("목표변수 :", target)
2 print("연속형(종속변수 포함):", continuous_cols)
3 print('독립변수(명목형):', nominal_cols)
4 print('독립변수(연속형):', feature_continuous)
5
6 display(df.head())
7 display(desc.head())
8 display(cat_desc.head())
```

목표변수 : charges
연속형(종속변수 포함): ['age', 'bmi', 'children', 'charges']
독립변수(명목형): ['sex', 'smoker', 'region']
독립변수(연속형): ['age', 'bmi', 'children']


	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.924
1	18	male	33.770	1	no	southeast	1725.552
2	28	male	33.000	3	no	southeast	4449.462
3	33	male	22.705	0	no	northwest	21984.471
4	32	male	28.880	0	no	northwest	3866.855

	count	mean	std	min	25%	50%	
age	1337.000	39.222	14.044	18.000	27.000	39.000	
bmi	1337.000	30.663	6.100	15.960	26.290	30.400	
children	1337.000	1.096	1.206	0.000	0.000	1.000	
charges	1337.000	13279.121	12110.360	1121.874	4746.344	9386.161	

	Unnamed: 0	sex	smoker	region
0	count	1337	1337	1337
1	unique	2	2	4
2	top	male	no	southeast
3	freq	675	1063	364

종속변수

```
1 fig, ax = my_plot.init(rows=1, cols=2, title=f'종속변수 {target}
2 분포', width=960, height=640)
3 my_plot.histplot(data=df, x=target, kde=True, ax=ax[0])
4 my_plot.boxplot(data=df, x=target, ax=ax[1])
5 my_plot.show()
```





점검항목	charges 관찰내용
분포모양(왜도)	오른쪽으로 치우침(우편향)
봉우리 수	낮은 보험료 구간에 1개 존재
이상치(박스플롯)	위쪽 수염 밖에 점 다수 존재
이산점(군집)	낮은 보험료 구간에 데이터가 집중되고, 높은 보험료 구간에 데이터 다소 분포

- charges는 낮은 보험료 구간에 값이 많이 몰려 있고, 오른쪽으로 긴 꼬리를 갖는 우편향 분포이다.
- 박스플롯에서도 위쪽 수염 밖에 높은 보험료 구간에 이상치가 확인되므로, 모델링 시 로그 변환(log1p)을 적용하는 것이 적절해보인다.


연속형 독립변수

```
1 for f in feature_continuous:
2     fig, ax = my_plot.init(rows=1, cols=2, title=f'독립변수 {f}
3     분포', width=960, height=640)
4     my_plot.histplot(data=df, x=f, kde=True, ax=ax[0])
5     my_plot.boxplot(data=df, x=f, ax=ax[1])
6     my_plot.show()
```






독립변수 bmi 분포



독립변수 children 분포



• 인사이트


변수	분포모양	봉우리	이상치	이산점(군집)	판단/조치
age	뚜렷한 좌우 치우침은 크지 않음	단봉	없음	-	그대로 사용 가능
bmi	약한 우편향	단봉	위쪽 수염 밖에 일부 점 존재	-	그대로 사용 가능
children	우편향	많음, 0명에 가장 많음	없음	0~5명으로 값이 분리	그대로 사용 가능

명목형


```
1 for n in nominal_cols:
2     # 빈도표 - 명목형 분포를 수치로
3     freq = df[n].value_counts().rename("빈도").to_frame()
4     freq['비율(%)'] = (df[n].value_counts(normalize=True) *
5 100).round(1)
6     display(freq)
7
8     # 명목형 분포는 카운트 플롯으로 처리한다.
    my_plot.countplot(data=df, x=n, title=f'독립변수 {n} 분포')
```

	빈도	비율(%)
cat		


sex		
male	675	50.500
female	662	49.500




	빈도	비율(%)
smoker		
no	1063	79.500
yes	274	20.500



	빈도	비율(%)
region		
southeast	364	27.200
southwest	325	24.300
northeast	324	24.200
northwest	324	24.200





• 인사이트

- 명목형은 분포 모양, 왜도 대신 범주의 균형/불균형을 점검하여 그대로 검정/모델에 넣어도 되는가를 판단한다.

변수	범주 수	빈도(비율)	균형 여부	판단/조치
sex	2 (male, female)	male: 675(50.5%), female: 662(49.5%)	균형	2집단이므로 charges와의 T검정 대상이며, 균형적이므로 그대로 사용 가능
smoker	2 (no, yes)	no: 1063(79.5%), yes: 274(20.5%)	불균형	2집단이므로 charges와의 T검정 대상
region	4 (northeast, northwest, southeast, southwest)	southeast: 364(27.2%), southwest: 325(24.3%), northwest: 325(24.3%), northeast: 323(24.2%)	대체로 균형	4집단이므로 charges와의 ANOVA 대상이며, 범주 비율이 비교적 균형적이므로 그대로 사용 가능


이변량 데이터 시각화


```

1 for f in feature_continuous:
2     # 연속 ↔ 연속: 산점도로 방향, 모양, 산포를 확인
3     my_plot.scatterplot(data=df, x=f, y=target, title=f'{f} ↔ {target}')


```

age ↔ charges






bmi ↔ charges



children ↔ charges



- 인사이트
- 연속 X 연속 → 산점도, 짝이 되는 검정은 상관분석(방향, 모양, 산포를 함께 본다)

변수	관찰된 관계(방향, 모양)	→검정
age	뚜렷한 양(+)(나이 ↑ → 보험료 ↑)	상관분석
bmi	약한 양(+)(산포 큼)	상관분석
children	거의 없음 혹은 아주 약한 양(+)(가장 낮은 보험료가 아이가 많은수목 약간씩 상승함)	상관분석


명목형 독립변수 ↔ 종속변수(박스플롯, 바이올린 → T검정)

```


1 for n in nominal_cols:
2     # 명목(2집단) ↔ 연속 : 박스플롯 + 바이올린으로 그룹 간 분포 비교
3     fig, ax = my_plot.init(rows=1, cols=2, title=f'{n} ↔
4 {target}', width=960, height=640)
5     my_plot.boxplot(data=df, x=n, y=target, hue=n, ax=ax[0])
6     my_plot.violinplot(data=df, x=n, y=target, hue=n, ax=ax[1])
7     my_plot.show()

```


sex ↔ charges



smoker ↔ charges



region ↔ charges




- 인사이트
- 명목(2집단) X 연속 → 박스플롯/바이올린, 짝이 되는 검정은 T검정
- 명목(3집단 이상) X 연속 → 박스플롯/바이올린, 짝이 되는 검정은 ANOVA

변수	관찰된 관계(방향)	→ 검정
sex	male의 charges 분포가 female보다 약간 위쪽	T검정
smoker	yes의 charges 중앙값이 no보다 뚜렷하게 높고 분포가 위쪽 → 흡연자 > 비흡연자	T검정
region	지역별 charges 중앙값과 분포가 대체로 비슷함 → 지역 차이 뚜렷하지 않음	ANOVA

- sex는 male과 female의 중앙값 차이가 아주 크지는 않지만, male 쪽에서 분포 범위가 더 넓다.
- 흡연자(smoker=yes)의 보험료가 비흡연자(smoker=no)보다 뚜렷하게 높다.
- smoker는 no 집단이 더 많고 yes 집단은 상대적으로 적지만, 박스플롯/바이올린에서 두 집단의 charges 차이가 크게 관찰된다.
- 지역(region)에 따른 보험료 차이는 크지 않아 보인다.
- 네 지역 모두 낮은 보험료 구간에 많이 분포하고, 고액 보험료 이상치는 여러 지역에서 관찰된다.
- 아직 눈으로 본 후보이므로, 실제 유의성, 효과크기는 추론통계 단계의 T검정 및 ANOVA에서 확인한다.

다변량 데이터 시각화

```
1 # 핵심변수 페어플롯 - 대각=분포(KDE), 비대각=산점도, 색상=명목형
2 (CHAS)
3 # 이변량에서 관계가 뚜렷했던 변수 + 종속변수만 선택(12개 전부는 정보
4 과부하)
5 core_cols = ['age', target]
  hue_col = 'smoker'
  my_plot.pairplot(data=df[core_cols + [hue_col]], hue=hue_col,
  diag_kind='kde', title=f'핵심 변수 페어플롯 (색상 = {hue_col})',
  width=480*4, height=320*4)
```



- 페어플롯으로 핵심변수들의 분포(대각)와 두 변수 관계(비대각)를 한번에 확인한다.
- charges 관계 : age는 charges와 양(+) 경향을 보인다. 즉 나이가 증가할수록 보험료가 증가하는 패턴이 관찰된다.
- 색상(smoker): 같은 age 구간에서도 smoker=yes 점들이 charges 위쪽(고액 보험료)에 뚜렷하게 분포한다 > 흡연자가 비흡연자보다 보험료가 높다는 후보 패턴 보강
- smoker 관계 : smoker=no는 낮은 보험료 구간에 많이 몰려 있고, smoker=yes는 중간~고액 보험료 구간까지 넓게 분포한다 > 흡연 여부가 charges 차이를 크게 나누는 핵심 변수 후보로 볼 수 있음
- 설명 변수끼리의 관계 : age와 smoker 사이에는 뚜렷한 선형 관계가 보이지 않는다 > 나이와 흡연 여부의 중복 가능성은 크지 않아 보임
- 여기까지는 모두 눈으로 본 후보다. 상관계수, 유의성 등 숫자 근거는 추론통계의 상관분석과 T검정에서 확인한다.

추론통계 후보 패턴 목록

#	변수조합(유형)	관찰된 패턴(방향, 근거 그래프)	→ 검정
01	age, charges(연속X연속)	age ↑ → charges ↑, 양(+) 경향이 비교적 뚜렷함(산점도, 페어플롯)	상관분석
	age, charges(연속X명목)	age ↑ → charges ↑, 양(+) 경향이 있음(산점도, 페어플롯)	상관분석

02	bmi, charges(연속X연속)	bmi ↑ → charges ↑, 각각 양(+) 경향이나 산포 큼(산점도)	상관분석
03	children, charges(연속X연속)	뚜렷한 선형 관계는 약함, 값이 0~5명으로 분리됨(산점도)	상관분석
04	sex, charges(명목2집단 X 연속)	male의 charges 분포가 female보다 약간 위쪽(박스, 바이올린)	T검정
05	smoker, charges(명목2집단 X 연속)	smoker=yes 집단의 charges 중앙값과 분포가 no보다 뚜렷하게 높음 = 흡연자 > 비흡연자(박스, 바이올린, 페어플롯)	T검정
06	region, charges(명목4집단 X 연속)	지역별 charges 중앙값과 분포가 대체로 비슷함, 뚜렷한 차이는 약함(박스, 바이올린)	ANOVA