

[LAB 08] 3. 추론통계

#연습문제

```
1 %%capture cap
2 %run "./08. PBT - EDA | 1-EDA 시작하기(연습문제).ipynb"
```

```
1 print("목표변수 :", target)
2 print("연속형(종속변수 포함):", continuous_cols)
3 print('독립변수(명목형):', nominal_cols)
4 print('독립변수(연속형):', feature_continuous)
5
6 display(df.head())
7 display(desc.head())
8 display(cat_desc.head())
```

목표변수 : charges
연속형(종속변수 포함): ['age', 'bmi', 'children', 'charges']
독립변수(명목형): ['sex', 'smoker', 'region']
독립변수(연속형): ['age', 'bmi', 'children']


	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.924
1	18	male	33.770	1	no	southeast	1725.552
2	28	male	33.000	3	no	southeast	4449.462
3	33	male	22.705	0	no	northwest	21984.471
4	32	male	28.880	0	no	northwest	3866.855

	count	mean	std	min	25%	50%
age	1337.000	39.222	14.044	18.000	27.000	39.000
bmi	1337.000	30.663	6.100	15.960	26.290	30.400
children	1337.000	1.096	1.206	0.000	0.000	1.000
charges	1337.000	13279.121	12110.360	1121.874	4746.344	9386.161

	Unnamed: 0	sex	smoker	region
0	count	1337	1337	1337
1	unique	2	2	4
2	top	male	no	southeast
3	freq	675	1063	364


```
1 from pandas import DataFrame, cut
```

```
1 for f in feature_continuous:
2     result = my_stats.correlation(df, x=f, y=target)
3     print(f'\n독립변수 : {f}')
4     display(result)
```




독립 변수 : age


		method	coef	p-value	strength	significant	normality_x
x	y						
age	charges	Spearman	0.533	0.000	Moderate	True	False



독립 변수 : bmi

		method	coef	p-value	strength	significant	normality_x
x	y						
bmi	charges	Spearman	0.120	0.000	Weak	True	False





독립 변수 : children

		method	coef	p-value	strength	significant	normalit
x	y						
children	charges	Spearman	0.132	0.000	Weak	True	False

- 인사이트
- 검정선택 : 모든 쌍에서 정규성 위배(normality=False) → Spearman P 자동 적용 (비모수). 3개 변수 모두 $p < 0.001$ 로 유의
- 채택기준 : $p < 0.05$ & $|r| > 0.3$ → 독립변수 후보로 채택

변수	coef	방향	강도	채택
age	0.533	정(+)	강함	채택
bmi	0.120	정(+)	약함	x
children	0.132	정(+)	약함	x

- 핵심 : age가 $|r|=0.533$ 로 charges와 가장 강한 양(+)의 상관 → 해당 변수가 보험료 설명력의 핵심 후보
- bmi와 children 두개 변수는 $|r| < 0.3$ (약함)이라 후보에서 제외
- 다만, 상관과 인과는 같지 않으므로 원인으로 단정짓지 않음

```
1 | my_stats.multi_correlation(df, columns=feature_continuous,
    | plot=False)
```

		method	coef	p-value	strength	significant	normality_x
x	y						
age	bmi	Spearman	0.108	0.000	Weak	True	False
	children	Spearman	0.056	0.041	Weak	True	False
bmi	children	Spearman	0.016	0.568	Weak	False	False

	age	bmi	children
age	1.000	0.108	0.056
bmi	0.108	1.000	0.016
children	0.056	0.016	1.000

- 인사이트
- 연속형 변수간 다중공선성 신호를 감지했을 때 강한 상관 변수쌍을 가진 값은 없음 ($|r| > 0.7$) - 다중 공선성 위험은 없음

T검정

이진 명목형 변수 ↔ 연속


```
1 smoker_charges = DataFrame({
2     "비흡연(no)": df.loc[df["smoker"] == "no",
3     target].reset_index(drop=True),
4     "흡연(yes)": df.loc[df["smoker"] == "yes",
5     target].reset_index(drop=True)
6 })

my_stats.test_independent(smoker_charges,"비흡연(no)","흡연(yes)",title="smoker에 따른 charges 차이")
```

p-value annotation legend:

- ns: $5.00e-02 < p \leq 1.00e+00$
- *: $1.00e-02 < p \leq 5.00e-02$
- **: $1.00e-03 < p \leq 1.00e-02$
- ***: $1.00e-04 < p \leq 1.00e-03$
- ****: $p \leq 1.00e-04$

비흡연(no) vs. 흡연(yes): Mann-Whitney-Wilcoxon test two-sided,
P_val:5.747e-130 U_stat=7.403e+03



		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	7403.000	0.000	True	비흡연(no) ≠ 흡연(yes)
	less	7403.000	0.000	True	비흡연(no) < 흡연(yes)
	greater	7403.000	1.000	False	비흡연(no) ≤ 흡연(yes)


```
1 sex_charges = DataFrame({
2     "여성(female)": df.loc[df["sex"] == "female",
3     target].reset_index(drop=True),
4     "남성(male)": df.loc[df["sex"] == "male",
5     target].reset_index(drop=True)
6 })

my_stats.test_independent(sex_charges, "여성(female)", "남성(male)", title="sex에 따른 charges 차이")
```

p-value annotation legend:

ns: 5.00e-02 < p <= 1.00e+00
*: 1.00e-02 < p <= 5.00e-02
**: 1.00e-03 < p <= 1.00e-02
***: 1.00e-04 < p <= 1.00e-03
****: p <= 1.00e-04

여성(female) vs. 남성(male): Mann-Whitney-Wilcoxon test two-sided,
P_val:6.945e-01 U_stat=2.207e+05



		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	220652.000	0.695	False	여성(female) = 남성(male)
	less	220652.000	0.347	False	여성(female) ≥ 남성(male)
	greater	220652.000	0.653	False	여성(female) ≤ 남성(male)

- 인사이트
- 명목(2) X 연속 → 두 변수 모두 T검정 계열, 정규성 위배 → Mann-Whitney U(비모수) 자동 적용

항목	smoker	sex
검정	Mann-Whitney U(비모수)	Mann-Whitney U(비모수)
U 통계량	7403	220652

p-value	<0.001(유의)	0.695
방향(단측)	비흡연(no) < 흡연(yes), $p<0.001$	$p>=0.05$
결론	흡연자(smoker=yes)의 charges가 더 높다	성별에 따른 charges 차이가 없다

- 해석 : 흡연 여부에 따라 보험료가 통계적으로 유의하게 다르며, 흡연자의 보험료가 더 비쌈
- $p<0.05$ 유의, → smoker를 독립변수 후보로 채택
- 비모수 검정이라 Cohen's d가 출력되지 않음 → 실질 크기는 박스플롯의 중앙값 차이로 보완판단

ANOVA

일원분산분석

```
1 | my_stats.anova_oneway(df, y='charges', between='region')
```

	test	Source	ddof1	ddof2	F	p_unc	np2	effect_size
0	welch_anova	region	3	740.416	2.566	0.053	0.007	Negligible

- 인사이트
- 명목(3+) x 연속 → ANOVA. 등분산 위배 → Welch_anova 자동적용

항목	결과
검정	Welch_anova(등분산 위배)
F	2.566
p-value	$>=0.053$ → 유의하지 않음
효과크기(np2)	0.007 → Negligible

- 해석 : 지역에 따라 charges가 통계적으로 유의하게 다르지 않음

```
1 |
```