

[LAB 09] 1. 선형회귀의 이해

#연습문제 - 골턴의 유산

```
1 from hossam import load_data
2 from helpers import *
3 from pandas import DataFrame
```

 아이티월 이광호 강사가 제작한 라이브러리를 사용중입니다.

 자세한 사용 방법은 <https://py.hossam.kr> 을 참고하세요.

 Email: leekh4232@gmail.com

 Youtube: <https://www.youtube.com/@hossam-codingclub>

 Blog: <https://blog.hossam.kr/>

 Version: 0.5.21

 'hossam' 패키지의 최신 버전이 출시되었습니다! (설치된 버전: 0.5.21, 최신 버전: 0.5.23)

최신 버전으로 업데이트하려면 다음 명령어를 실행하세요:

```
pip install --upgrade hossam
```

```
1 origin = load_data('father-son')
2 origin.head()
```

 아버지와 아들의 키를 조사한 데이터 (출처:

<https://www.kaggle.com/datasets/aungdev/pearson-dataset-heights-of-fathers-and-their-sons>)

field	description
fheight	아버지의 키(Inches)
sheight	아들의 키(Inches)

	fheight	sheight
0	65.049	59.778
1	63.251	63.214
2	64.955	63.342
3	65.752	62.792
4	61.137	64.281

미션 1. 데이터와 친해지기

- 크기, 자료형, 기초통계량 확인
- 산점도를 그려 아버지 키와 아들 키 사이에 어떤 경향이 보이는지 눈으로 관찰
- 두 변수의 상관계수를 구하고 회귀분석을 적용해도 되는지 근거를 대라

```
1 origin.info()
```


```
<class 'pandas.DataFrame'>
RangeIndex: 1078 entries, 0 to 1077
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  -
0   fheight     1078 non-null   float64
1   sheight     1078 non-null   float64
dtypes: float64(2)
memory usage: 17.0 KB
```

1 | my_qtcheck.numerical_summary(origin).T

	fheight	sheight
count	1078.000	1078.000
mean	67.687	68.684
std	2.745	2.815
min	59.008	58.507
25%	65.788	66.931
50%	67.767	68.616
75%	69.603	70.466
max	75.434	78.365
rel_diff	0.001	0.001
rdiff_flag	similar	similar
iqr	3.815	3.535
upper_bound	75.326	75.768
lower_bound	60.065	61.629
upper_outliers	1	8
upper_outliers_ratio	0.001	0.007
lower_outliers	5	11
lower_outliers_ratio	0.005	0.010
outliers	6	19
outliers_ratio	0.006	0.018
skew	-0.088	-0.037
skew_interpret	symmetric	symmetric
kurt	-0.156	0.539
kurt_interpret	platykurtic	leptokurtic
log_need	none	none

1 | my_stats.correlation(origin,x='fheight', y='sheight', plot=True, title='아버지 키와 아들 키의 상관관계', xlabel='아버지 키 (fheight)', ylabel='아들 키(sheight)')

아버지 키와 아들 키의 상관관계



		method	coef	p-value	strength	significant	normalit
x	y						
fheight	sheight	Spearman	0.506	0.000	Moderate	True	True

p-value가 <0.001로 매우 유의하고 r이 0.506로 유의한 양의 중간 상관관계가 있고 선형성을 띄므로 회귀분석을 적용할 수 있음

미션 2. 회귀식 유도하기

- 아들 키를 종속변수, 아버지 키를 독립변수로 하는 단순선형회귀모형
- 추정결과로부터 회귀식을 도출하여 제시

```
1 | fit = my_ols.fit_model(origin, y='sheight', summary=True)
```

OLS Regression Results					
=====					
==					
Dep. Variable:	sheight		R-squared:		
0.251					
Model:	OLS		Adj. R-squared:		
0.251					
Method:	Least Squares		F-statistic:		
361.2					
Date:	Mon, 06 Jul 2026		Prob (F-statistic):		1.12e-
69					
Time:	12:27:44		Log-Likelihood:		
-2488.7					
No. Observations:	1078		AIC:		
4981.					
Df Residuals:	1076		BIC:		
4991.					
Df Model:	1				
Covariance Type:	nonrobust				
=====					
==					
	coef	std err	t	P> t	[0.025
0.975]					

--					
const	33.8866	1.832	18.493	0.000	30.291

```

-----
37.482
fheight      0.5141      0.027      19.006      0.000      0.461
0.567
=====
==
Omnibus:                  17.605   Durbin-Watson:
0.767
Prob(Omnibus):            0.000   Jarque-Bera (JB):
30.849
Skew:                    -0.051   Prob(JB):                  2.00e-
07
Kurtosis:                3.822   Cond. No.
1.67e+03
=====
==

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 1.67e+03. This might indicate that there are strong multicollinearity or other numerical problems.

- $y = ax + b$ (단순선형회귀)
- $a = 0.5141$, $b = 33.8866$
- 예측할 수 있는 아들의 키 = $0.5141 \times \text{아버지키} + 33.8866$

미션 3. 아버지 키에 따른 아들의 키 예측

- 새로운 데이터셋을 만들어 앞서 유도한 회귀식으로 각자의 아들 키를 예측하라

```

1  from pandas import concat
2
3  df = origin.copy()
4  df['pred'] = float('nan')
5
6  new_fathers = DataFrame({'fheight': [62, 65, 68, 71, 74]})
7  new_fathers['sheight'] = float('nan')
8  new_fathers['pred'] = my_ols.predict(fit,
9  new_fathers[['fheight']])['pred']
10
11 df = concat([df, new_fathers], ignore_index=True)
    df.tail()

```

	fheight	sheight	pred
1078	62.000	NaN	65.760
1079	65.000	NaN	67.303
1080	68.000	NaN	68.845
1081	71.000	NaN	70.387
1082	74.000	NaN	71.929

미션 4. 한장의 그래프로 보고하기

```
1 df_melt = df.melt(
2     id_vars='fheight',
3     value_vars=['sheight', 'pred'],
4     var_name='variable',
5     value_name='value'
6 )
7
8 df_melt.tail(10)
```

	fheight	variable	value
2156	66.997	pred	NaN
2157	71.332	pred	NaN
2158	71.783	pred	NaN
2159	70.738	pred	NaN
2160	70.306	pred	NaN
2161	62.000	pred	65.760
2162	65.000	pred	67.303
2163	68.000	pred	68.845
2164	71.000	pred	70.387
2165	74.000	pred	71.929

```
1 my_plot.lmplot(df_melt, x='fheight', y='value', hue='variable',
2     title='아버지 키에 따른 아들의 키', xlabel='아버지 키', ylabel='아
3     들 키')
```

아버지 키에 따른 아들의 키

