

[LAB 09] 2-2. 가정 검정 모듈화

#연습문제

```
1 from hossam import load_data
2 from helpers import *
```

 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.

 자세한 사용 방법은 <https://py.hossam.kr> 을 참고하세요.

 Email: leekh4232@gmail.com

 Youtube: <https://www.youtube.com/@hossam-codingclub>

 Blog: <https://blog.hossam.kr/>

 Version: 0.5.21

 'hossam' 패키지의 최신 버전이 출시되었습니다! (설치된 버전: 0.5.21, 최신 버전: 0.5.23)

최신 버전으로 업데이트하려면 다음 명령어를 실행하세요:

```
pip install --upgrade hossam
```

```
1 origin = load_data('father-son')
2 origin.head()
```

 아버지와 아들의 키를 조사한 데이터 (출처:

<https://www.kaggle.com/datasets/aungdev/pearson-dataset-heights-of-fathers-and-their-sons>)

	fheight	sheight
0	65.049	59.778
1	63.251	63.214
2	64.955	63.342
3	65.752	62.792
4	61.137	64.281

```
1 fit = my_ols.fit_model(origin, y='sheight')
2 fit
```

```
<statsmodels.regression.linear_model.RegressionResultsWrapper at
0x20a762ab380>
```

문제 1. 잔차(resid)와 적합값(y_pred)을 추출하라


```
1 ols_df = origin.copy()
2 ols_df['y_pred'] = fit.fittedvalues
3 ols_df['resid'] = fit.resid
4 ols_df.head()
```

	fheight	sheight	y_pred	resid
0	65.049	59.778	67.328	-7.549
1	63.251	63.214	66.403	-3.189
2	64.955	63.342	67.280	-3.937
3	65.752	62.792	67.690	-4.897
4	61.137	64.281	65.317	-1.036

문제 2. 선형성과 등분산성 확인

```
1 my_ols.test_linear(fit)
2 my_ols.test_equalvar(fit)
```

	statistic	p-value	linearity	result
Ramsey RESET	0.032	0.859	True	귀무가설 채택 → 선형성 위배 근거 없음




	LM statistic	LM p-value	F statistic	F p-value	homoscedasticity	result
Breusch-Pagan	0.003	0.960	0.003	0.960	True	귀무가설 채택 → 등분산성 만족

- 잔차-적합값 산점도를 확인해보니, 잔차가 0을 중심으로 무작위하게 분포하고 뚜렷한 곡선 패턴이 보이지 않는다. 뚜렷하게 곡선의 형태를 보이지 않았기 때문에 선형성 가정은 대체로 만족한다고 판단하였다. 또한 Ramsey RESET 검정의 p-value가 0.05 이상이면 선형성을 위배하였다는 근거가 있다고 볼 수 없다.
- Breusch-Pagan 검정 결과 F p-value가 0.05 이상으로 귀무가설을 채택하여 등분산성 가정을 만족한다고 판단한다.

문제 3. 정규성


```
1 | my_ols.test_normal(fit)
```

	statistic	p-value	normality	result
Kolmogorov-Smirnov	0.022	0.667	True	귀무가설 채택 → 정규성 만족



	기대(%)	허용범위(%)	실제(%)	판정
구간				
$\pm 1\sqrt{\text{MSE}}$	68.000	65~71	71.430	위배
$\pm 2\sqrt{\text{MSE}}$	95.000	94~96	95.730	충족
$\pm 3\sqrt{\text{MSE}}$	99.700	99~100	98.700	위배

$\sqrt{\text{MSE}} = 2.44$ / 구간 규칙 판정 : 정규성 위배



```
1 | from scipy.stats import shapiro
2 | from pandas import DataFrame
3 |
4 | method = "Shapiro-Wilk"
5 | s, p = shapiro(fit.resid)
6 |
7 | DataFrame([ {
```

```
8         'statistic': round(s, 4),
9         'p-value': round(p, 4),
10        'normality': p >= 0.05,
11        "result": "귀무가설 채택 → 정규성 만족" if p >= 0.05 else "대
12립가설 채택 → 정규성 위배"
    }], index=[method])
```

	statistic	p-value	normality	result
Shapiro-Wilk	0.993	0.000	False	대립가설 채택 → 정규성 위배

- Q-Q plot을 확인한 결과, 잔차의 중앙 부분은 기준선에 대체로 일치하고 양쪽 꼬리 부분에서 잔차들이 기준선에서 벗어남을 보인다.
- Shapiro-Wilk 검정에서는 p-value < 0.001로 0.05보다 작아 귀무가설을 기각하고 정규성을 만족하지 못한다고 판단한다.
- KS 검정에서는 p-value = 0.667 > 0.05로 정규성 위반 근거가 없다.
- $\pm\sqrt{\text{MSE}}$ 구간 규칙에서도 $\pm 1\sqrt{\text{MSE}}$ 와 $\pm 3\sqrt{\text{MSE}}$ 구간이 기대 비율에서 벗어나 정규성을 충족하지 못했다.

문제 4. 독립성과 종합판정

```
1 | my_ols.test_independent(fit)
```

	statistic	independence	result
Durbin-Watson	0.766	False	독립성 위반 (양(+))의 자기상관

- Durbin-Watson 통계량이 1.5보다 작으므로 양의 자기상관 가능성이 있다. 따라서 독립성 가정이 위배될 수 있다.

4대 가정 종합결론

- 회귀식 $\text{sheight} = 0.51 * \text{fheight} + 33.89$ ($R^2 = 0.251$, $n=1078$)

가정	검정(도구)	수치	판정
선형성	Ramsey RESET	0.859	만족
정규성	K-S(권장) / Shapiro(참고)	KS p = 0.667	만족
등분산성	Breusch-Pagan	0.960	만족
독립성	Durbin-Watson	DW=0.766	위반

- 네 가지 가정의 진단결과 해당 회귀모형은 대체로 신뢰 가능하다.
- 잔차-적합값 산점도에서 뚜렷한 곡선 패턴이 보이지 않았고 Ramsey RESET 검정의 p-value가 0.859로 0.05보다 커 선형성 위배 근거가 없었다.
- KS 검정에서도 p-value가 0.667로 0.05보다 크게 나타나 정규정을 만족하였다. 물론 Shapiro-Wilk 검정의 p-value가 0.001보다 작아 정규성 가정은 완전히 만족하

지 못한다고 유의해야 하나 $n=1078$ 이므로 중심극한정리(CLT)로 계수 추론에는 큰 문제가 없다.

- Breusch-Pagan 검정에서도 F p-value가 0.960으로 등분산성 가정을 만족하였다.
- 독립성이 0.766으로 1.5보다 작아 양의 자기상관이 존재할 가능성이 있으나 이 회귀모형은 시계열 데이터가 아니므로 해당 검정은 크게 신경쓰지 않아도 될 것이라고 생각된다. 따라서 본 회귀모형은 신뢰 가능한 모형이라고 판단된다.