

[LAB 09] 3-2. 회귀분석 결과보고 모듈화

연습문제 1 - 골턴의 유산 - 분석결과 보고

```
1 # 라이브러리 기본 참조
2 from hossam import load_data
3 from helpers import *
4 from IPython.display import display, Markdown
```

 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
 자세한 사용 방법은 <https://py.hossam.kr> 을 참고하세요.
 Email: leekh4232@gmail.com
 Youtube: <https://www.youtube.com/@hossam-codingclub>
 Blog: <https://blog.hossam.kr/>
 Version: 0.5.21

 'hossam' 패키지의 최신 버전이 출시되었습니다! (설치된 버전: 0.5.21, 최신 버전: 0.5.23)
최신 버전으로 업데이트하려면 다음 명령어를 실행하세요:
`pip install --upgrade hossam`

```
1 origin = load_data('father-son')
2 origin.head()
```

 아버지와 아들의 키를 조사한 데이터 (출처:
<https://www.kaggle.com/datasets/aungdev/pearson-dataset-heights-of-fathers-and-their-sons>)

	fheight	sheight
0	65.049	59.778
1	63.251	63.214
2	64.955	63.342
3	65.752	62.792
4	61.137	64.281

```
1 fit = my_ols.fit_model(origin, 'sheight', summary=True)
```

OLS Regression Results

=====

==

Dep. Variable:	sheight	R-squared:	
0.251			
Model:	OLS	Adj. R-squared:	
0.251			
Method:	Least Squares	F-statistic:	
361.2			
Date:	Wed, 08 Jul 2026	Prob (F-statistic):	1.12e-
69			
Time:	13:07:22	Log-Likelihood:	
-2488.7			

No. Observations: 1078 AIC: 4981.
Df Residuals: 1076 BIC: 4991.
Df Model: 1
Covariance Type: nonrobust

=====

==

	coef	std err	t	P> t	[0.025
0.975]					

--					
const	33.8866	1.832	18.493	0.000	30.291
37.482					
fheight	0.5141	0.027	19.006	0.000	0.461
0.567					
=====					
==					
Omnibus:	17.605		Durbin-Watson:		
0.767					
Prob(Omnibus):	0.000		Jarque-Bera (JB):		
30.849					
Skew:	-0.051		Prob(JB):	2.00e-	
07					
Kurtosis:	3.822		Cond. No.		
1.67e+03					
=====					
==					

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 1.67e+03. This might indicate that there are strong multicollinearity or other numerical problems.

```
1 # 회귀계수 표
2 vdf = my_ols.report_variables(fit, origin)
3 display(vdf)
4
5 # 모형적합도 보고 (로그변환 없음)
6 display(Markdown(my_ols.report_fitness(fit)))
7
8 # 독립변수 보고(로그변환 없음)
9 display(Markdown(my_ols.report_variables_text(fit)))
```

	종속변수	독립변수	B	표준 오차	β	t	유의 확률	공차	VIF
0	sheight	fheight	0.514	0.027	0.501	19.006	0.000	1.000	1.000

Note. n = 1078. F(1, 1076) = 361.23, p < 0.001, R² = 0.251, Adj.R² = 0.251, Durbin_Watson = 0.767

sheight를 종속변수로, fheight(을)를 독립변수로 한 단순선형회귀분석 결과, 모형은 통계적으로 유의하였다.

F(1, 1076) = 361.23 , p < 0.001, R² = 0.251.

즉, fheight는 sheight의 약 25.13%를 설명하는 것으로 나타났다.

- `fheight`의 회귀계수는 $B = 0.51$ 으로 나타났으며, 이는 `sheight`에 유의한 요인임을 의미한다. ($t(1076) = 19.01, p < .001$) 즉, `fheight`가 1 증가할 때 `sheight`는 평균적으로 0.51 증가하는 것으로 해석된다.

연습문제 2 - 근속년수에 따른 연봉 예측모델 만들기

```
1 df = load_data('salary')
2 df.head()
```

 경력 (년 차)에 따른 연봉 (USD) 데이터 (출처: <https://www.kaggle.com/datasets/abhishek14398/salary-dataset-simple-linear-regression>)

	field	description
0	YearsExperience	경력 (년 차)
1	Salary	연봉 (USD)

	YearsExperience	Salary
0	1.200	39344.000
1	1.400	46206.000
2	1.600	37732.000
3	2.100	43526.000
4	2.300	39892.000

```
1 df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 30 entries, 0 to 29
Data columns (total 2 columns):
#   Column          Non-Null Count  Dtype
---  -
0   YearsExperience  30 non-null    float64
1   Salary          30 non-null    float64
dtypes: float64(2)
memory usage: 612.0 bytes
```

```
1 my_qtcheck.numerical_summary(df).T
```

	YearsExperience	Salary
count	30.000	30.000
mean	5.413	76004.000
std	2.838	27414.430
min	1.200	37732.000


25%	3.300	56721.750
50%	4.800	65238.000
75%	7.800	100545.750
max	10.600	122392.000
rel_diff	0.128	0.165
rdiff_flag	diff	diff
iqr	4.500	43824.000
upper_bound	14.550	166281.750
lower_bound	-3.450	-9014.250
upper_outliers	0	0
upper_outliers_ratio	0.000	0.000
lower_outliers	0	0
lower_outliers_ratio	0.000	0.000
outliers	0	0
outliers_ratio	0.000	0.000
skew	0.380	0.354
skew_interpret	symmetric	symmetric
kurt	-1.012	-1.295
kurt_interpret	platykurtic	platykurtic
log_need	none	none

미션 1. 기술통계량 확인 후 인사이트

- 기술통계량을 확인한 결과, 전체 데이터는 30개로 구성되어 있으며 결측치와 이상치는 확인되지 않았다. 별도의 결측치 처리나 이상치 제거 과정은 필요하지 않은 것으로 판단된다.
- 또한 두 변수의 skew 왜도를 확인해보니 대칭에 가까운 형태를 보였으며 첨도는 낮게 나타나 특정 값에 과도하게 집중된 형태는 아니었고, 비교적 완만한 분포를 보였다. 로그 변환은 불필요한 것으로 판단된다.

```
1 my_stats.correlation(df,x='YearsExperience', y='Salary',
  plot=True, title='근속연수와 연봉의 상관관계', xlabel='근속연수
    (YearsExperience)', ylabel='연봉(Salary)')
```

근속연수와 연봉의 상관관계





		method	coef	p-value	strength	significant	nc
x	y						
YearsExperience	Salary	Spearman	0.957	0.000	Strong	True	Tr

미션 2. 탐색적 데이터 분석 - 모델설계

- 정규성 검정 결과 정규성 가정을 충족하지 않아, 비모수 상관분석 방법인 Spearman 상관분석을 실시하였다. 분석 결과 p-value가 <0.001로 나타나 두 변수 간 상관관계는 통계적으로 매우 유의하였다. 상관계수 $r = 0.957$ 로 나타나 두 변수는 매우 강한 양의 상관관계가 있는 것으로 확인되었다.
- 산점도를 확인한 결과 근속년수가 증가할수록 연봉이 증가하는 선형적 경향이 확인되었다. 따라서 근속년수는 연봉을 예측하는 데 적합한 설명변수로 판단되며, 이후 단순선형회귀분석을 적용할 수 있다.

미션 3.

- $y = ax + b$ (단순선형회귀)
- $a = 9449.9623, b = 2.485e+04$
- 예측 연봉 = $9449.96 \times \text{근속년수} + 24,850$

```
1 | fit = my_ols.fit_model(df, y='Salary', summary=True)
```

OLS Regression Results						
=====						
==						
Dep. Variable:	Salary		R-squared:			
0.957						
Model:	OLS		Adj. R-squared:			
0.955						
Method:	Least Squares		F-statistic:			
622.5						
Date:	Wed, 08 Jul 2026		Prob (F-statistic):		1.14e-	
20						
Time:	14:59:38		Log-Likelihood:			
-301.44						
No. Observations:	30		AIC:			
606.9						
Df Residuals:	28		BIC:			
609.7						
Df Model:	1					
Covariance Type:	nonrobust					
=====						
=====						
	coef	std err	t	P> t	[0.025	
0.975]						

1	0.405104	0.006654	60.732	0.000	0.391104	0.419104

```
const          2.485e+04    2306.654      10.772      0.000      2.01e+04
2.96e+04
YearsExperience 9449.9623    378.755      24.950      0.000      8674.119
1.02e+04
=====
==
Omnibus:                2.140    Durbin-Watson:
1.648
Prob(Omnibus):          0.343    Jarque-Bera (JB):
1.569
Skew:                   0.363    Prob(JB):
0.456
Kurtosis:               2.147    Cond. No.
13.6
=====
==
```

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
1 # 회귀계수 표
2 vdf = my_ols.report_variables(fit, df)
3 display(vdf)
4
5 # 모형적합도 보고 (로그변환 없음)
6 display(Markdown(my_ols.report_fitness(fit)))
7
8 # 독립변수 보고(로그변환 없음)
9 display(Markdown(my_ols.report_variables_text(fit)))
```

	종속 변수	독립변수	B	표준오 차	β	t	유의 확률	공
0	Salary	YearsExperience	9449.962	378.755	0.978	24.950	0.000	1.00

Note. n = 30. F(1, 28) = 622.51, p < 0.001, R² = 0.957, Adj.R² = 0.955, Durbin_Watson = 1.648

Salary를 종속변수로, YearsExperience(을)를 독립변수로 한 단순선형회귀분석 결과, 모형은 통계적으로 유의하였다.

F(1, 28) = 622.51 , p < 0.001, R² = 0.957.

즉, YearsExperience는 Salary의 약 95.7%를 설명하는 것으로 나타났다.

- YearsExperience의 회귀계수는 B = 9449.96으로 나타났으며, 이는 Salary에 유의한 요인임을 의미한다. (t(28) = 24.95, p < .001) 즉, YearsExperience가 1 증가할 때 Salary는 평균적으로 9449.96 증가하는 것으로 해석된다.